

RAPPORT DE GROUPE EN SCIENCES DES DONNÉES 4

ADELL Lona, HAOUASNIA Mayssoune, LAASILI Omia, LARIANI Kenza



Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université Paul Valéry, Montpellier 3

Mai 2025

SOU MIS COMME CONTRIBUTION
POUR LE COURS SCIENCE DES DONNÉES 4

Déclaration de non plagiat

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : HAOUASNIA Mayssoune

Date : 11/04/2025

Signature : LARIANI Kenza

Date : 11/04/2025

Signature : LAASILI OMIA

Date : 11/04/2025

Signature : ADELL Lona

Date : 11/04/2025

Remerciements

Nos plus sincères remerciements vont à nos encadrants pédagogiques pour les conseils avisés sur notre travail. Nous remercions tout particulièrement Mme Sandra Bringay, Mme Namrata Patel et Mr Michel Theodore Picque pour leur soutien précieux et leur expertise.

Résumé

Ce projet vise à concevoir un outil numérique complet pour l'analyse des risques de cancer, en s'appuyant sur trois types de données complémentaires : des mammographies, des biopsies avec mesures morphologiques des tumeurs, ainsi que des données biométriques et sanguines. L'objectif principal est d'offrir une plateforme interactive, à destination des chercheurs et des professionnels de santé, pour explorer, visualiser et prédire le caractère bénin ou malin des tumeurs.

Le site propose des sections dédiées à l'analyse exploratoire, à la visualisation statistique et à la prédiction par modèles. Pour les chercheurs, l'outil facilite la détection de corrélations entre variables et l'identification de facteurs de risque. Pour les médecins, il constitue une aide précieuse au diagnostic, en apportant des prédictions automatisées fondées sur des données historiques, contribuant à une prise en charge plus rapide et plus précise.

Table des matières

Chapitre 1 Introduction	1
Chapitre 2 Gestion de projet	3
2.1 Introduction	3
2.2 Collaboration avec Git	3
2.3 Contribution	4
2.4 Planning	5
2.5 Conclusions	6
Chapitre 3 Base de données	7
3.1 Provenance des données	7
3.2 Descriptif des tables	8
3.3 Modèle conceptuel des données	10
3.4 Modèle organisationnel des données	11
3.5 Conclusions	12
Chapitre 4 Rapport technique : Construction du site Oncoanalyse	13
4.1 Structure et composition du site	13
4.1.1 Section "À propos"	13
4.1.2 Section "Exploration"	13
4.1.3 Section d'Analyse Statistique	14
4.1.4 Section "visualisation"	14
4.1.5 Section "Prédiction par images médicales"	14
4.1.6 Section "Prédiction du risque de cancer"	15
4.2 Mise en place du versionnage et collaboration	15
4.3 Améliorations esthétiques significatives	15
4.4 Défis techniques et solutions mises en œuvre	16
4.5 Conclusion	16
4.6 Description technique	16
Chapitre 5 Analyse Statistique	17
Chapitre 6 Visualisation	21
6.1 Données biopsie de tumeur (brca)	22
6.1.1 Graphe Réseau	22
6.1.2 ACP	23
6.1.3 Nuage de points	25
6.1.4 Boxplot ciblant l'aire des tumeurs	26
6.1.5 Vulgarisation de la tumeur	27
6.2 Données biométriques et sanguines	28
6.2.1 Barplot – Corrélation des données biométriques et sanguines	28

6.2.2	Matrice de corrélation	29
6.2.3	Boxplot par diagnostic	30
6.2.4	Sunburst interactif	31
Chapitre 7 Prédiction		32
7.1	Jeu de données sur les biopsies morphologiques d'une tumeur	32
7.2	Jeu de données sur les analyses sanguines	33
7.3	Prédiction par Deep Learning pour les Images Médicales	36
7.3.1	Pourquoi le Deep Learning	36
7.3.2	Pourquoi les CNN	36
7.3.3	Architecture utilisée	37
7.3.4	Source de données	37
7.3.5	Traitement des images	37
7.3.6	Division de la base de données	38
7.3.7	Résultats avant amélioration	38
7.3.8	Amélioration avec VGG et autres techniques	38
7.3.9	Résultats après amélioration	38
7.3.10	Expérience sur Orange et développement Flask	40
7.3.11	Conclusions	40
Chapitre 8 Conclusion		41

CHAPITRE 1

Introduction

« Et si la donnée devenait une alliée de taille dans la lutte contre le cancer ? »

C'est à partir de cette question que notre projet est né. Dans un contexte où la rapidité et la précision du diagnostic peuvent sauver des vies, nous avons voulu concevoir un outil capable de soutenir à la fois les chercheurs et les professionnels de santé dans l'analyse et la compréhension des tumeurs cancéreuses.

Notre site web, à la fois interactif et intuitif, repose sur l'exploitation croisée de plusieurs sources de données médicales : des images de mammographies, des résultats de biopsies morphologiques, ainsi que des données biométriques et sanguines. L'objectif est double : permettre l'analyse approfondie des caractéristiques des tumeurs bénignes et malignes, et offrir des outils prédictifs fiables pour accompagner le diagnostic médical.

Pour les chercheurs, la plateforme constitue un puissant outil d'analyse exploratoire, enrichi de visualisations interactives et de traitements statistiques avancés. Elle leur permet d'identifier des corrélations, de déceler des patterns cachés, et ainsi de mieux comprendre les facteurs de risque associés au cancer.

Pour les médecins, le site fournit des prédictions sur le caractère bénin ou malin des tumeurs, fondées sur des jeux de données historiques et des algorithmes de machine learning. Ces prédictions peuvent être intégrées à la prise de décision clinique, en complément des examens classiques, tout en réduisant le temps nécessaire à l'évaluation des risques.

Ce projet se situe donc à la croisée de la recherche et de la pratique clinique : il vise à accélérer le processus de diagnostic, à améliorer la précision des soins, et à contribuer à une meilleure prise en charge des patients.

Ce qui rend notre projet unique, c'est sa capacité à regrouper en une seule plateforme des sources de données variées — biométriques, sanguines et morphologiques — tout en offrant à la fois des outils d'analyse statistique, de visualisation interactive et de prédiction des risques. Contrairement aux outils classiques souvent limités à un seul type de données ou à une fonctionnalité, notre site s'adresse simultanément aux chercheurs et aux médecins, avec des interfaces et des fonctionnalités pensées pour leurs besoins spécifiques. Cette approche multidimensionnelle permet non seulement d'enrichir la compréhension des tumeurs, mais aussi d'accélérer la prise de décision clinique. Pour faire connaître notre projet, nous pourrions envisager une diffusion dans les milieux universitaires et hospitaliers, ainsi qu'auprès des centres de recherche en oncologie, via des conférences, publications spécialisées ou réseaux professionnels comme LinkedIn.

Le rapport se structure en plusieurs chapitres détaillant l'ensemble du projet et des travaux réalisés. Le premier chapitre introduit le sujet et la problématique du projet.

Ensuite, le chapitre 2 aborde la gestion de projet, incluant la collaboration avec Git, la répartition des tâches et le planning. Le chapitre 3 présente la base de données, sa provenance, son organisation et les modèles de données utilisés. Le chapitre 4 décrit la construction du site Oncoanalyse, en détaillant les différentes sections et les défis techniques rencontrés. Le chapitre 5 fournit une analyse statistique approfondie des données, suivie du chapitre 6 qui présente les différentes visualisations réalisées. Le chapitre 7 est consacré aux prédictions, y compris les méthodes de Deep Learning appliquées aux images médicales, avec une attention particulière aux améliorations techniques. Enfin, le chapitre 8 conclut le rapport en résumant les résultats obtenus et les perspectives d'amélioration.

Pour voir notre soutenance : <https://www.youtube.com/watch?v=SRpu0HkYIm4jjj>.

Pour accéder à notre site web : <https://lightslategray-falcon-114804.hostingersite.com/>.

CHAPITRE 2

Gestion de projet

2.1 Introduction

Dans le cadre de ce projet, nous avons eu à réaliser un site web sur le sujet de notre choix. Pour travailler d'une manière plus efficace, nous allons décrire la gestion de ce projet et la répartition des tâches tout au long de ce semestre.

Pour commencer, on va présenter le développement du projet. On va détailler les méthodes utilisées, la collaboration de l'équipe ainsi que la contribution de chacune. Le développement de notre projet s'est appuyé sur une organisation claire, une répartition des tâches efficace et une communication constante au sein de l'équipe. Tout au long du semestre, nous avons suivi une méthodologie itérative favorisant la collaboration et l'amélioration continue.

Nous avons débuté par la phase de conception, durant laquelle nous avons défini les besoins fonctionnels du site. Cette étape nous a permis d'établir les objectifs du projet et de répartir les différents codages des sections (exploration, analyse, visualisation, prédiction) entre les membres de l'équipe. Une fois validé par tous les membres et les professeurs, on passe à la dernière phase : l'architecture du site et l'injection du code. Ce schéma sera réalisé chaque semaine.

Lien GitHub : <https://github.com/omialaasili/Oncoanalyse>

2.2 Collaboration avec Git

Dans le cadre de ce projet, nous avons utilisé Git principalement comme outil de centralisation et de sauvegarde de notre code. Bien que le développement ait été réparti entre les membres de l'équipe (chacune travaillant de son côté sur une section précise), nous avons organisé une phase de fusion finale en fin de projet pour rassembler nos travaux respectifs. Chaque membre de l'équipe a développé sa partie sur sa propre machine, puis a créé une branche dédiée lors de la mise en commun. Cela nous a permis d'intégrer progressivement chaque section afin de faciliter la fusion et de limiter les risques de conflits.

Comme les développements ont été réalisés de manière indépendante, les conflits étaient relativement rares. Lorsqu'ils se sont présentés, nous les avons résolus manuellement en comparant les fichiers concernés. Cela nous a permis de mieux comprendre le fonctionnement des conflits Git et leur résolution.

Bien que nous ayons chacune nos sections il fallait tout de même se référer à un modèle de base pour que notre site soit cohérent.

2.3 Contribution

Description	Mayssoune	Kenza	Omia	Lona
Recherche données	40	0	60	0
MOD/MCD	70	0	30	0
Analyse exploratoire	20	0	70	10
Visualisation	50	10	40	0
Intégration du projet sur Git	20	40	20	20
Prédiction brca	100	0	0	0
Prédiction IMG	0	50	50	0
Prédiction risque	0	0	0	100
Architecture du site	25	25	25	25
Interactivité/esthétique du site	10	40	50	0
Relier site	50	0	50	0
Rédaction du rapport	25	25	25	25
Hébergement	30	40	30	0

TABLE 2.1: Répartition des tâches entre les membres du groupe en %

Description	Mayssoune	Kenza	Omia	Lona
index.php	20	20	40	20
index.sectionPrédiction	0	100	0	0
index.graphe	10	0	90	0
analyseResultat.php	0	0	100	0
predictionrisque.php	0	0	0	100
traite.php	0	0	0	100
tumeurVisu.php	100	0	0	0
tumeurVisu2.php	100	0	0	0
traitement.php	100	0	0	0
signup.php	0	100	0	0
login.php	0	100	0	0

TABLE 2.2: Contribution de chacun par page en %

2.4 Planning




FIGURE 2.1: Roadmap du premier semestre




FIGURE 2.2: Diagramme de GRANT semestre 2

Au second semestre, certaines tâches ont pu être réalisées plus rapidement grâce à une meilleure maîtrise du sujet. Après avoir bien compris les objectifs du projet lors du premier semestre, nous avons acquis une meilleure compréhension des besoins pour le site web. Cela nous a permis de savoir exactement ce que nous devons rechercher et ce que l'on attendait de chaque fonctionnalité. De plus, la gestion des versions sur Git a été plus fluide, les conflits étaient moins fréquents et mieux résolus, car chaque membre avait une idée plus précise de l'architecture du projet.

Cette meilleure maîtrise a permis de réduire le temps passé à clarifier des concepts ou des attentes, ce qui s'est traduit par un gain de temps global, en particulier lors des phases de développement web.

2.5 Conclusions

La gestion du projet a évolué de façon importante quand chacune a compris ses tâches comme on le voit dans le diagramme de GANTT. Cela nous a conduit à une collaboration plus fluide et grâce aux tableaux de répartition des tâches et à l'utilisation de Git, on voit que bien que chaque membre ait eu une implication égale dans le projet, nos méthodes de travail étaient différentes. Certaines ont choisi de travailler de manière plus autonome avant de partager leur code, tandis que d'autres ont préféré intégrer leurs modifications plus régulièrement. Nous avons tous pu avancer à notre propre rythme tout en assurant une cohésion grâce à une communication continue et une gestion des versions maîtrisée via Git.

CHAPITRE 3

Base de données

3.1 Provenance des données

Pour commencer, la collecte des données s'est faite en ligne via le site kaggle :

- Base de données 1 : brca au format csv (1Ko), cet ensemble de données contient les caractéristiques morphologiques d'une tumeur (cancer du sein) tirées d'une biopsie. Il répertorie au total 569 tumeur dont 357 bénignes et 212 malignes. Le jeu de données se résume en 4 parties. Avec 32 variables (dont l'identifiant) et aucune valeur nulle. La première représente le relevé moyen effectué sur la tumeur, la deuxième l'erreur-type possible et la troisième la plus défavorable. Elle se nomme tumeur.

<https://www.kaggle.com/datasets/utkarshx27/breast-cancer-wisconsin-diagnostic-resource=download>

	A	B	C	D	E	F	G
1		x.radius_mean	x.texture_mean	x.perimeter_mean	x.area_mean	x.smoothness_mean	x.compactness_mean
2	1	13.54	14.36	87.46	566.3	0.09779	0.08129
3	2	13.08	15.71	85.63	520	0.1075	0.127
4	3	9.504	12.44	60.34	273.9	0.1024	0.06492
5	4	13.03	18.42	82.61	523.8	0.08983	0.03766
6	5	8.196	16.84	51.71	201.9	0.086	0.05943
7	6	12.05	14.63	78.04	449.3	0.1031	0.09092
8	7	13.49	22.3	86.91	561	0.08752	0.07698
9	8	11.76	21.6	74.72	427.9	0.08637	0.04966
10	9	13.64	16.34	87.21	571.8	0.07685	0.06059
11	10	11.94	18.24	75.71	437.6	0.08261	0.04751
12	11	11.52	18.75	73.34	409	0.09524	0.05473

FIGURE 3.1: tumeur

Nous avons importé le fichier renommé tumeur.csv dans MAMP ou WAMP pour créer une BD cancer.sql qui permettra d'utiliser les données en passant par un code sql pour faciliter la gestion et l'utilisation sur le site web. Avant l'importation, la colonne y a été enlevé, le renommage des noms des colonnes, deux colonnes id-tumeur et code_diagnostic ont été ajouté et la création d'un nouveau fichier diagnostic.csv qui comporte deux colonne code_diagnostic et libelle_diagnostic.

- Base de données 2 : dataR2 au format csv (7,48 Ko), cet ensemble de données concerne 116 analyses sanguines de différentes personnes. Elles réunissent 10 informations comme l'âge, l'IMC, le taux de glucose dans le sang ... Elle se nomme patient.

<https://www.kaggle.com/datasets/ankitbarai507/breast-cancer-dataset>

	A	B	C	D	E	F	G	H	I	J	K
1	id_patient	age	bmi	glucose	insulin	homa	leptin	adiponectin	resistin	mcp1	classification
2	1	48	23.5	70	2.707	0.467408667	8.8071	9.7024	7.99585	417.114	1
3	2	83	20.69049454	92	3.115	0.706897333	8.8438	5.429285	4.06405	468.786	1
4	3	82	23.12467037	91	4.498	1.009651067	17.9393	22.43204	9.27715	554.697	1
5	4	68	21.36752137	77	3.226	0.612724933	9.8827	7.16956	12.766	928.22	1
6	5	86	21.11111111	92	3.549	0.8053864	6.6994	4.81924	10.5763	773.92	1
7	6	49	22.85445769	92	3.226	0.732086933	6.8317	13.67975	10.3176	530.41	1
8	7	89	22.7	77	4.69	0.890787333	6.964	5.589865	12.9361	1256.083	1
9	8	76	23.8	118	6.47	1.883201333	4.311	13.25132	5.1042	280.694	1
10	9	73	22	97	3.35	0.801543333	4.47	10.358725	6.28445	136.855	1
11	10	75	23	83	4.952	1.013839467	17.127	11.57899	7.0913	318.302	1
12	11	34	21.47	78	3.469	0.6674356	14.57	13.11	6.92	354.6	1

FIGURE 3.2: patient

Nous avons importé le fichier renommé patient.csv dans MAMP ou WAMP pour créer une BD patient.sql qui permettra d'utiliser les données en passant par un code sql pour faciliter la gestion et l'utilisation sur le site web. Avant l'importation, une colonne id_patient a été ajouté et le renommage des noms des colonnes.

- Base de données 3 : le premier jeu de données contient 3 413 images (640x640p) de mammographie au format png/jpg réparti en 3 dossiers test (366 images), train (2 372 images) et valid (675 images). Ces trois dossiers sont structurés de la même manière : deux dossiers 0 et 1.

<https://www.kaggle.com/datasets/hayder17/breast-cancer-detection>

Le deuxième jeu de données contient 1 578 images (500x500p) de mammographie au format png répartie en 3 dossiers benin (891 images), malin(421 images) et normal(266 images).

<https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset>

Au total, il y a 4991 images de mammographie.

3.2 Descriptif des tables

TABLE 3.1: tumeur (569 × 32)

Nom colonne	Type	Signification	Caractéristique
id-tumeur	int	identité tumeur (1 à 569)	clé primaire
rayon_moyen	float	rayon du noyau (moyen)	
texture_moyenne	float	texture du noyau (moyen)	
perimetre_moyen	float	périmètre du noyau(moyen)	
air_moyenne	float	zone du noyau (moyen)	
uniformite_moyenne	float	lissage du noyau (moyen)	
compact_moyen	float	compacité du noyau (moyen)	
concavite_moyenne	float	concavité du noyau (moyen)	
nconcavite_moyenne	float	nombre de parties concaves du contour du noyau (moyen)	
symetrie_moyenne	float	symétrie du noyau (moyen)	
dim_fractal_moyenne	float	dimension fractale du noyau (moyen)	
rayon_se	float	rayon du noyau (erreur-type)	
texture_se	float	texture du noyau (erreur-type)	

Nom colonne	Type	Signification	Caractéristique
perimetre_se	float	périmètre du noyau (erreur-type)	
air_se	float	zone du noyau (moyen)	
uniformite_se	float	lissage du noyau (erreur-type)	
compact_se	float	compacité du noyau (erreur-type)	
concavite_se	float	concavité du noyau (erreur-type)	
nconcavite_se	float	nombre de parties concaves du contour du noyau (erreur-type)	
symetrie_se	float	symétrie du noyau (erreur-type)	
dim_fractal_se	float	dimension fractale du noyau (erreur-type)	
rayon_worst	float	rayon du noyau (plus défavorable)	
texture_worst	float	texture du noyau (plus défavorable)	
perimetre_worst	float	périmètre du noyau (plus défavorable)	
air_worst	float	zone du noyau (plus défavorable)	
uniformite_worst	float	lissage du noyau (plus défavorable)	
compact_worst	float	compacité du noyau (plus défavorable)	
concavite_worst	float	concavité du noyau (plus défavorable)	
nconcavite_worst	float	nombre de parties concaves du contour du noyau (plus défavorable)	
symetrie_worst	float	symétrie du noyau (plus défavorable)	
dim_fractal_worst	float	dimension fractale du noyau (plus défavorable)	
code_diagnostic	int	identité diagnostic (1 à 2)	clé étrangère

TABLE 3.2: diagnostic (2 × 2)

Nom colonne	Type	Signification	Caractéristique
code_diagnostic	int	identité diagnostic (1 à 2)	clé primaire
libelle_diagnostic	varchar	Bénigne (B) ou Maligne (M)	

TABLE 3.3: patient (116 × 11)

Nom colonne	Type	Signification	Caractéristique
id_patient	int	identité patient (1 à 116)	clé primaire
age	int	age de patient	
bmi	float	indice de masse corporelle (kg/m²)	
glucose	float	niveau de glucose dans le sang (mg/dL)	
insulin	float	niveau d'insuline (µU/mL)	
homa	float	indice estimant la résistance à l'insuline	
leptin	float	hormone régulant l'appétit le métabolisme (ng/mL)	
adiponectin	float	hormone liée à la sensibilité à l'insuline (µg/mL)	
resistin	float	hormone associée à l'inflammation	

Nom colonne	Type	Signification	Caractéristique
mcp1	float	et au diabète (ng/mL) protéine impliquée dans l'inflammation (pg/dL)	
classification	tinyint	1 = en bonne santé, 2 = patient malade	

3.3 Modèle conceptuel des données

Voici le modèle MCD réalisé avec le logiciel Mocodo [<https://www.mocodo.net/>] pour base de données 1, voir Figure 3.3 ci-dessous :




FIGURE 3.3: Relations de cancer.sql

Voici le modèle MCD réalisé avec le logiciel Mocodo pour base de données 2, voir Figure 2.4 ci-dessous :




FIGURE 3.4: Relation de patient.sql

3.4 Modèle organisationnel des données

Le MOD de base de données 1 :

tumeur (id-tumeur, rayon_moyen, texture_moyenne, perimetre_moyen, air_moyenne, uniforme_moyenne, compact_moyen, concavite_moyenne, nconcavite_moyenne, symetrie_moyenne, dim_fractal_moyenne, rayon_se, texture_se, perimetre_se, air_se, uniforme_se, compact_se, concavite_se, nconcavite_se, symetrie_se, dim_fractal_se, rayon_worst, texture_worst, perimetre_worst, air_worst, uniforme_worst, compact_worst, concavite_worst, nconcavite_worst, symetrie_worst, dim_fractal_worst, code_diagnostic)

diagnostic (code_diagnostic, libelle_diagnostic)





FIGURE 3.5: Relations de cancer.sql

Le MOD de base de données 2 :

patient (id-patient, age, glucose, insulin, homa, leptin, adiponectin, resistin, mcp1,
classification)



The image shows a screenshot of a database schema viewer. At the top, there is a header bar with a blue 'v' icon, a gear icon, and the text 'patient patient'. Below this, a list of columns is displayed, each with a small icon and its data type. The columns are: 'id_patient' (int(11)) with a key icon, 'age' (int(11)) with a hash icon, 'bmi' (float) with a hash icon, 'glucose' (float) with a hash icon, 'insulin' (float) with a hash icon, 'homa' (float) with a hash icon, 'leptin' (float) with a hash icon, 'adiponectin' (float) with a hash icon, 'resistin' (float) with a hash icon, 'mcp1' (float) with a hash icon, and 'classification' (tinyint(4)) with a hash icon.

Column	Type
id_patient	int(11)
age	int(11)
bmi	float
glucose	float
insulin	float
homa	float
leptin	float
adiponectin	float
resistin	float
mcp1	float
classification	tinyint(4)

FIGURE 3.6: Relations de patient.sql

3.5 Conclusions

Lors de la création des bases de données cancer.sql et patient.sql, les bases 1 et 2 ont été mises en place rapidement, sans difficulté particulière.

CHAPITRE 4

Rapport technique : Construction du site Oncoanalyse

4.1 Structure et composition du site

Notre site est structuré en cinq sections principales, chacune avec des objectifs et fonctionnalités spécifiques :

4.1.1 Section "À propos"

Pourquoi cette section ? Pour offrir une introduction claire à la plateforme et créer une première impression positive.

Composition technique :

- Structure HTML en deux colonnes avec la classe CSS "wave-two-cols"
- Présentation textuelle dans une boîte avec effets d'ombre et de survol
- Image d'illustration médicale avec effets de transition au survol
- Composant bouton avec dégradé et animation subtile

```
1 .wave-two-cols .text-content:hover {  
2   transform: translateY(-5px);  
3   /* Effet subtil de "flottement" au survol */  
4 }
```

Listing 4.1: Effet de survol sur les contenus textuels

4.1.2 Section "Exploration"

Pourquoi cette section ? Pour permettre l'analyse comparative des données de tumeurs via différentes visualisations.

Composition technique :

- Système de segmentation entre deux jeux de données (biopsies/données biométriques)
- Interface à onglets pour naviguer entre les visualisations
- 9 graphiques différents implémentés avec Chart.js et Plotly.js
- Système d'animation lors des transitions entre graphiques

```
1 function showGraph(id) {  
2   // Ce syst me permet une transition fluide entre les  
3   graphiques  
4   // sans rechargement brutal des visualisations  
5   document.querySelectorAll('.graph-container').forEach(div =>  
6     {  
7       if (div.id !== id && div.classList.contains('show')) {  
8         div.classList.remove('show');  
9         div.classList.add('hide');  
10        setTimeout(() => { div.style.display = 'none'; },  
11          500);  
12      }  
13    });  
14 }
```

```

9      }
10     });
11 }

```

Listing 4.2: Système de transition entre graphiques

4.1.3 Section d'Analyse Statistique

Pour faciliter l'exploration des données de tumeurs, nous avons développé une interface d'analyse statistique interactive.

Pourquoi cette approche ? Pour permettre aux utilisateurs de sélectionner précisément les caractéristiques qui les intéressent.

Composition technique :

- Formulaire avec cases à cocher générées dynamiquement
- Zone de défilement pour nombreux paramètres
- Validation empêchant la soumission sans sélection
- Redirection vers une page d'analyse dédiée

4.1.4 Section "visualisation"

Pourquoi cette section ? Pour offrir un accès direct aux données individuelles des tumeurs dans la base de données.

Composition technique :

- Interface en deux colonnes (sélection à gauche, aperçu à droite)
- Menu déroulant pour sélectionner le type de données (M/SD/W)
- Liste interactive des tumeurs avec leurs diagnostics
- Requête SQL avec jointure pour récupérer les informations pertinentes

```

1 // Cette requête associe chaque tumeur son diagnostic
  correspondant
2 $query = $conn->query("SELECT tumeur.'Id-tumeur', diagnostic.
  libelle_diagnostic
3                               FROM tumeur
4                               JOIN diagnostic ON tumeur.code_diagnostic =
                                     diagnostic.code_diagnostic");

```

Listing 4.3: Requête SQL pour associer tumeurs et diagnostics

4.1.5 Section "Prédiction par images médicales"

Pourquoi cette section ? Pour permettre l'analyse d'images médicales par IA et présenter les résultats de façon claire.

Composition technique :

- Interface d'upload avec prévisualisation d'image
- Animation de progression pendant l'analyse
- Présentation contextuelle des résultats avec indicateur de confiance
- 5 visualisations des performances du modèle implémentées avec Plotly.js
- Système d'aide contextuelle pour chaque graphique

```

1 // Code qui adapte l'affichage en fonction du diagnostic
2 document.getElementById("result-content").innerHTML = '
3     <div style="text-align:center;">
4         <h4 style="color:${statusColor};">Tumeur ${statusText}</
      h4>

```

```

5      <!-- Barre de confiance avec animation progressive -->
6      <div style="height:8px; background:#eee; border-radius:4
      px; overflow:hidden;">
7          <div style="height:100%; width:0; background:${
      statusColor};
8              transition:width 1s ease-in-out;"></div>
9      </div>
10     </div>
11     ‘;

```

Listing 4.4: Affichage contextuel des résultats

4.1.6 Section "Prédiction du risque de cancer"

Pourquoi cette section ? Pour offrir une analyse prédictive basée sur des marqueurs sanguins et biochimiques.

Composition technique :

- Formulaire de saisie des paramètres biométriques et sanguins
- Connexion à une API utilisant un modèle Random Forest
- Interface de présentation des résultats avec niveau de risque
- Visualisation des facteurs influençant la prédiction

Cette section s'appuie sur un modèle de Machine Learning préalablement testé et sélectionné parmi plusieurs algorithmes (kNN, SVM, Tree, Random Forest, Logistic Regression). Le modèle Random Forest a été retenu pour ses performances supérieures (accuracy de 0.92) et son excellent équilibre entre les deux classes de prédiction.

4.2 Mise en place du versionnage et collaboration

Pour gérer le développement collaboratif du site, nous avons implémenté un système de versionnage avec Git. Cette implémentation a comporté plusieurs aspects :

1. **Création du repository et structure initiale**
 - Configuration du repository distant
 - Organisation des branches (main, develop, features)
 - Définition des règles de contribution
2. **Workflow de développement**
 - Travail sur des branches séparées pour chaque fonctionnalité
 - Tests locaux avant chaque push
 - Fusion après validation du code

4.3 Améliorations esthétiques significatives

Notre refonte a considérablement transformé l'apparence du site via plusieurs techniques :

1. **Système de design cohérent**
 - Palette de couleurs signifiante (bleu pour bénin, rose-rouge pour malin)
 - Arrondis et ombres portées pour donner de la profondeur
 - Animations subtiles pour les interactions
2. **Animations au défilement**
 - Apparition progressive des sections lors du scroll
 - Transitions douces entre les états des composants
 - Retour visuel immédiat pour toutes les interactions

```

1 .section-fade-in {
2     opacity: 0;
3     transform: translateY(30px);
4     transition: opacity 0.8s ease, transform 0.8s ease;
5 }
6
7 .section-fade-in.visible {
8     opacity: 1;
9     transform: translateY(0);
10 }

```

Listing 4.5: Animation des sections au défilement

4.4 Défis techniques et solutions mises en œuvre

Au cours du développement, nous avons rencontré plusieurs obstacles techniques que nous avons su surmonter :

1. Problèmes d’environnement et de compatibilité

Solution : Création de fichiers de configuration séparés pour chaque environnement et standardisation des chemins avec des variables définies au début des scripts.

2. Conflits lors du versionnage collaboratif

Solution : Établissement d’un workflow strict avec revues de code et branches dédiées aux fonctionnalités.

3. Communication avec les API de prédiction

Solution : Mise en place d’un middleware pour gérer les requêtes CORS et standardisation du format des échanges JSON.

4. Intégration du modèle de prédiction du risque

Solution : Bien que l’automatisation complète de l’API n’ait pas pu être finalisée, nous avons développé une solution fonctionnelle manuelle en attendant de résoudre les problèmes d’intégration.

4.5 Conclusion

La transformation d’Oncoanalyse illustre l’importance d’une interface utilisateur intuitive pour les outils d’analyse médicale complexes. En combinant des fonctionnalités avancées de visualisation, d’analyse de données et de prédiction par IA avec une esthétique soignée et cohérente, nous avons créé une plateforme qui facilite véritablement le travail des professionnels de santé dans l’analyse des tumeurs mammaires.

Les défis techniques rencontrés ont été abordés méthodiquement, et bien que certains aspects comme l’intégration automatique de l’API de prédiction du risque restent à perfectionner, la base solide que nous avons établie permettra des évolutions futures facilitées. L’expérience acquise lors de cette refonte constitue un atout précieux pour les développements à venir.

4.6 Description technique

logiciels utilisés : GitHub, Mamp, Python, Javascript, PHP, SQL, Discord, WAMP

CHAPITRE 5

Analyse Statistique

Objectif de la section

Cette section a pour objectif de permettre aux chercheurs d'accéder aux statistiques essentielles des biopsies des tumeurs de manière rapide et efficace. Elle offre aussi des options d'export pour une utilisation ultérieure. Elle est conçue principalement pour les chercheurs en oncologie qui nécessitent un accès rapide, précis et personnalisé aux statistiques des données des biopsies. Cette section est uniquement basée sur la base de données de données des biopsies.

Les fonctionnalités proposées

La sélection des caractéristiques | L'utilisateur peut choisir les caractéristiques des tumeurs à analyser (par exemple, le rayon, la texture, le périmètre, etc.). Les caractéristiques sont directement récupérées depuis la base de données des tumeurs.

Comparaison Statistique des caractéristiques des tumeurs bénignes et malignes | Les statistiques calculées pour chaque caractéristique sont comparées entre les tumeurs bénignes et malignes, permettant aux chercheurs de déduire les tendances mais aussi, de ré-utiliser ces résultats lors de leurs études plus approfondies.

Matrice de covariance | L'utilisateur aura également accès à une matrice de covariance, qui mesure la relation entre les caractéristiques choisies par le chercheur.

Export CSV personnalisé | Après l'analyse, les utilisateurs peuvent exporter leurs résultats sous forme de fichier(s) CSV, offrant ainsi une flexibilité pour une utilisation personnelle ultérieure.

Code et fonctionnement général

Connexion à la base de données | Le code commence par une connexion à la base de données afin de récupérer les caractéristiques des tumeurs. La fonction `getBD()` assure cette connexion, puis une requête SQL récupère les noms des colonnes des caractéristiques disponibles (sauf l'ID de la tumeur). Une fois la connexion établie, la requête est exécutée pour récupérer les noms des caractéristiques, qui sont ensuite affichés dans le formulaire de sélection.

Sélection des caractéristiques | Le formulaire HTML permet à l'utilisateur de sélectionner 1 à plusieurs caractéristiques à analyser. Ces choix sont envoyés au fichier `analyseRésultat.php` pour le traitement. Le formulaire est conçu pour s'assurer que l'utilisateur sélectionne au moins une caractéristique, avec un contrôle côté serveur pour vérifier la validité des données.

Calcul des statistiques | Pour chaque caractéristique choisie par le chercheur, des statistiques comme la moyenne, l'écart-type, la médiane, et les quartiles sont calculées. Ces statistiques sont essentielles pour comparer les deux types de tumeurs. Méthode de calcul : La moyenne est calculée en faisant la somme de toutes les valeurs divisée par le nombre total de données qu'on retrouve également dans le tableau. L'écart-type est obtenu à partir de la variance des données. Les calculs sont effectués à l'aide de fonctions PHP dédiées, telles que `array_sum()` pour la somme des valeurs par exemple. La médiane et les quartiles sont calculés grâce à des fonctions de tri et d'extraction des valeurs situées aux positions en question.

La matrice de covariance | Cette étape consiste à calculer la matrice de covariance, qui mesure la relation entre plusieurs caractéristiques. Cela permet de détecter des corrélations ou des dépendances entre elles. Une matrice est calculée pour les tumeurs bénignes et une autre pour les tumeurs malignes, deux tableaux supplémentaires sont donc affichés afin de faciliter l'interprétation. Une matrice de covariance permet de voir comment les caractéristiques des tumeurs varient ensemble. Par exemple, si deux caractéristiques (comme le rayon et le périmètre) sont fortement corrélées, cela pourrait indiquer une relation forte entre elles, ce qui est utile pour les chercheurs. Le calcul de la matrice de covariance est réalisé en utilisant une fonction PHP personnalisée qui prend en compte toutes les paires de caractéristiques sélectionnées. Les résultats sont affichés sous forme de tableaux pour une consultation plus pratique pour les chercheurs.

Visualisation des résultats avec un exemple concret

Exemple de comparaison statistique des caractéristiques des tumeurs | Supposons que l'utilisateur sélectionne le périmètre moyen et le rayon moyen des tumeurs.




FIGURE 5.1: Choix rayon moyen et périmètre moyen

En comparant les statistiques des tumeurs bénignes et malignes, on peut observer les résultats suivants :

Résultats de l'analyse

Statistiques descriptives et matrices de covariance

Comparaison Statistique				
Stat/Type	rayon_moyen (B)	rayon_moyen (M)	perimetre_moyen (B)	perimetre_moyen (M)
Count	357	212	357	212
Moyenne	12.15	17.46	78.08	115.37
Écart-type	1.78	3.2	11.81	21.85
Min	6.98	10.95	43.79	71.9
Q1	11.08	15.06	70.87	98.64
Médiane	12.2	17.3	78.18	114.2
Q3	13.37	19.59	86.1	129.9
Max	17.85	28.11	114.6	188.5

FIGURE 5.2: Comparaison statistique des caractéristiques des tumeurs bénignes et malignes

Pour le périmètre moyen, la moyenne des tumeurs bénignes est de 78.08, tandis que celle des tumeurs malignes est de 115.37. Pour le rayon moyen, la moyenne des tumeurs bénignes est de 12.15, et celle des tumeurs malignes est de 17.46. On sait que les tumeurs malignes ont tendance à présenter des caractéristiques plus grandes à cause de leur nature plus agressive par rapport aux tumeurs bénignes.

Exemple de matrice de covariance | L'utilisateur peut également visualiser la matrice de covariance pour observer les relations entre le périmètre moyen et le rayon moyen.



FIGURE 5.3: Matrices de covariances entre le perimetre moyen et le rayon moyen

Par exemple, dans le cas des tumeurs bénignes, la covariance entre ces deux caractéristiques est de 20.96 tandis que pour les tumeurs malignes elle est de 69.69. Cette différence montre que les tumeurs malignes pourraient avoir une corrélation plus forte entre le périmètre et le rayon moyen que les tumeurs bénignes.

CHAPITRE 6

Visualisation

Objectif de la section

Cette section a pour objectif de permettre aux chercheurs de visualiser les tendances et les corrélations présentes dans nos jeux de données grâce à des représentations graphiques claires, personnalisées et interactives. Elle est conçue principalement pour les chercheurs en oncologie qui nécessitent un accès rapide personnalisé à l'exploration visuelle des données. Cette section est basée sur deux jeux de données utilisés dans le projet : celui sur les biopsies ainsi que celui sur les données biométriques et sanguines.

Les fonctionnalités proposées

La sélection du jeu de données | Afin de simplifier et d'accélérer l'expérience de navigation et d'analyse pour le chercheur, il est possible de sélectionner le jeu de données qu'il souhaite explorer. Les jeux de données étant indépendants, l'utilisateur peut choisir s'il souhaite analyser les graphiques générés à partir des données de biopsie, ou bien, des données biométriques et sanguines. Ce choix est important car il permet de générer des graphiques adaptés au type de données sélectionné. Ainsi, le chercheur accède directement au diaporama des visualisations correspondant à ses besoins, ce qui rend l'exploration plus rapide et plus claire.

6.1 Données biopsie de tumeur (brca)

6.1.1 Graphe Réseau




FIGURE 6.1: Graphe Réseau selon le seuil de corrélation

C'est un graphe qui a pour sommet les attributs et en arrête la corrélation. Il affiche selon le seuil de corrélation les arrête entre les les attributs. Cette visualisation permet de voir quels sont les liens entre les variables de la tumeur. On considère que plus un sommet à un degrés élevé plus cette variable est importante pour la visualisation.

Les librairies utilisées sont : pandas, networkx, numpy et plotly
code généré par ChatGPT.

Corps du code : python.py Calcul de la matrice de corrélation, création de positions aléatoires pour les sommets, fonction pour dessiner les arrêtes selon un seuil avec un seuil initial de 0.5 et échelle pour changer le seuil de corrélation.

6.1.2 ACP




FIGURE 6.2: ACP à deux composante

Ce graphe se base sur l'ACP, où on a réduit les dimensions comprenant toutes les variables moyennes. L'axe horizontale présente la première composante et l'axe verticale représente la deuxième composante. On distingue aussi deux couleurs de points en bleu les tumeurs bénignes et en rouge les tumeurs malignes. L'ACP montre une bonne séparation entre les tumeurs, les malignes ont des valeurs plus fortes sur ces dimensions, elles sont présentes plus à droite. Les bénignes sont plus groupées avec des valeurs plus faibles à gauche. Même si la séparation n'est pas nette entre les deux tumeurs, cette ACP montre qu'il est envisageable de faire une classification supervisée.




FIGURE 6.3: Diagramme de Voronoi sur ACP

Pour visualiser quels pourraient être les modèles qu'on peut utiliser, on a décidé de faire un diagramme de Voronoi sur l'ACP. Ce diagramme sert à représenter des cellules (ici oranges) autour d'un ensemble de points comme des clusters. Il est utile pour comprendre la séparation entre les classes. En bas à gauche, les cellules bleues sont très petites et très serrées, ça traduit une forte densité locale de cette classe. Cette homogénéité peut suggérer qu'un modèle linéaire simple (comme la régression logistique ou le SVM linéaire) pourrait déjà bien prédire cette classe. Cependant les cellules rouges sont plus grandes, irrégulières, et certaines sont isolées. Ça indique une classe moins homogène et plus variée. Un modèle de type Random Forest ou un réseau de neurones pourrait être plus adapté. On voit des cellules rouges et bleues qui se touchent. Ces points sont probablement plus

difficiles à classifier (zone d'ambiguïté). C'est dans ces zones que le modèle fera le plus d'erreurs

librairies utilisées : pandas, numpy, matplotlib, sklearn.
Code généré par ChatGPT.
vernoi.py




FIGURE 6.4: Frontière sur ACP des modèles de Régression Logistique et SVM-Linéaire




FIGURE 6.5: Frontière sur ACP du modèle MLP

Les figures ci-dessus comparent les frontières de décision obtenues par trois modèles de classification (une régression logistique, un SVM linéaire, et un réseau de neurones (MLP)) sur les données projetées dans l'espace réduit à deux dimensions par l'ACP. Pour la Régression Logistique, Le modèle trace une frontière linéaire relativement simple entre les deux classes. Il effectue une séparation correcte, bien qu'il laisse passer quelques points mal classés près de la frontière. Le SVM linéaire génère également une frontière linéaire, mais elle est légèrement différente de celle de la régression logistique. Il semble offrir une séparation un peu plus stricte. Et pour le réseau de neurones contrairement aux deux précédents, est capable d'apprendre des frontières non linéaires. Cela lui permet d'épouser davantage la structure complexe des données. On remarque que sa zone de décision s'adapte mieux aux zones plus confuses, même si elle reste relativement lisse ici (probablement dû à la faible dimension de l'espace de l'ACP).

Globalement, ces visualisations sont utiles pour comprendre la capacité des différents modèles à séparer les classes. Un réseau de neurones peut offrir des performances plus flexibles, mais au prix d'une complexité plus grande et d'un risque de sur-apprentissage si les paramètres ne sont pas bien régulés.

Code Figure 5.4

librairies utilisées : pandas, numpy, sklearn, ploty

code généré par ChatGPT

typepred.py

Code Figure 5.5

librairies utilisées : pandas, numpy, sklearn, ploty

code généré par ChatGPT

reseau.py

6.1.3 Nuage de points




FIGURE 6.6: Sélection attribut pour nuage de point




FIGURE 6.7: Nuage de points selon la variable choisit

Pour explorer une à une les caractéristiques des tumeurs mammaires, nous avons opté pour une représentation graphique en nuage de points de nos données pour voir la différence entre bénigne et maligne. Ce graphique interactif permet de sélectionner une caractéristique (comme le rayon moyen, le périmètre moyen, la texture moyenne . . .) et de visualiser ces données : en bleu bénigne et en orange maligne. Cela permet aux chercheurs de voir où se situent graphiquement nos données des tumeurs mammaires et de les aider dans leurs recherches.

6.1.4 Boxplot ciblant l'aire des tumeurs




FIGURE 6.8: Boxplot ciblant les caractéristiques liées à l'aire des tumeurs

Avant de sélectionner les variables à afficher, un boxplot global de l'ensemble des caractéristiques des tumeurs a été réalisé. Il était clair que les caractéristiques liées à l'aire se démarquaient nettement entre les groupes de tumeurs bénignes et malignes. Pour des raisons de lisibilité, seules ces trois variables ont été retenues : l'aire moyenne, l'aire standardisée et l'aire worst.

On observe que les boxplots correspondant au groupe B (tumeurs bénignes) sont globalement plus bas, avec une dispersion plus faible et des valeurs significativement inférieures à celles du groupe M (tumeurs malignes). Par exemple, le troisième quartile (Q3) est de 551,25 pour les tumeurs bénignes, contre 1204,5 pour les tumeurs malignes. Cet écart se retrouve également pour l'aire standardisée et l'aire worst, relevant l'intérêt de ces variables pour différencier les types de tumeurs lors de biopsies.

Librairies utilisées : `plotly.graph_objects`, `pandas` et `os`

Code généré à l'aide de ChatGPT sur la base de requêtes réalisées personnellement.

Fichier python : `analyseBiopsieTumeur.py`

6.1.5 Vulgarisation de la tumeur




FIGURE 6.9: Visualisation 3D interactive d'une tumeur

Le but de cette visualisation est de vulgariser un peu la tumeur à partir des données morphologiques. L'utilisateur choisi la tumeur qu'il souhaite visualiser (large choix de bénigne à maligne).

```
theta = np.linspace(0, 2 * np.pi, 100)
phi = np.linspace(0, np.pi, 100)
theta, phi = np.meshgrid(theta, phi)

r = radius * (1 + concavity * np.sin(3 * phi) * np.cos(3 * theta) +
              smoothness * np.sin(phi) +
              symmetry * np.cos(theta) * 0.1)

r += fractal_dim * 0.2 * np.sin(5 * theta) * np.cos(5 * phi)
```

FIGURE 6.10: Enter Caption

L'utilisateur aura ensuite une sphère, fixée avec le rayon auquel on ajoute 1 pour commencer une déformation. On multiplie la concavité à sin et cos qui vont aussi créer des déformations donc des bosses et des creux. On va chercher à venir lisser certaines parties pour qu'elles soient plus ou moins étirées avec smoothness. La symétrie va venir rajouter une certaine régularité. On termine par rajouter des ondulations sur la surface et on terminera de créer et d'afficher la sphère.

librairies utilisées : numpy, ploty
 code généré par ChatGPT
 testvisu.py

6.2 Données biométriques et sanguines

6.2.1 Barplot – Corrélation des données biométriques et sanguines



FIGURE 6.11: Enter Caption

Avant d’interpréter les relations entre les variables, un graphique de corrélation dynamique a été mis en place, permettant au chercheur de sélectionner une variable depuis une liste déroulante. Ce système interactif permet de générer automatiquement un barplot affichant les coefficients de corrélation entre la variable choisie et toutes les autres présentes dans le jeu de données.

Par exemple, si l’on sélectionne la variable *age*, le graphique indique une corrélation négative de -0,219813 avec la variable *adiponectin* (en $\mu\text{g/mL}$). À l’inverse, en sélectionnant *insulin* (en uU/mL), une forte corrélation positive de 0,93219 est observée avec *homa* (indice d’insulino-résistance). Ce résultat n’est pas étonnant, d’après le site http://mediatheque.lecrips.net/doc_num.php?explnum_id=48927, l’indice HOMA est calculé directement à partir des concentrations de glucose et d’insuline, via la formule : $HOMA = \text{Insuline} \times \text{Glucose} / 22,5$.

Ce type de visualisation permet donc une exploration ciblée des liens entre variables, essentielle pour identifier les relations les plus pertinentes dans le cadre de la recherche.

Librairies utilisées : plotly.graph_objects, pandas et os

Code généré à l’aide de ChatGPT sur la base de requêtes réalisées personnellement.

Fichier python : analysePatients.py

6.2.2 Matrice de corrélation




FIGURE 6.12: Matrice de corrélation

Afin d'offrir une vue d'ensemble claire des relations entre les variables du jeu de données biométriques et sanguins, une matrice de corrélation a été retenue. Celle-ci utilise un code couleur allant du bleu (corrélation positive) au rouge (corrélation négative), avec une intensité variable selon la force de la corrélation.

La diagonale principale est colorée en bleu foncé : elle représente la corrélation d'une variable avec elle-même.

Dans l'ensemble, la matrice est dominée par des nuances de bleu, révélant de nombreuses corrélations positives, allant de 0,1 à 0,93. Parmi les plus élevées, on peut citer les couples *leptin* (ng/mL) et *bmi* (IMC), *insulin* et *homa*, ainsi que *homa* et *glucose*. À l'inverse, certaines corrélations positives sont plus faibles, comme entre *age* et *mcp-1* (pg/dL).

Les corrélations négatives sont plus modérées, apparaissant en rouge clair/orange, avec des valeurs comprises entre -0,03 et -0,30. La valeur la plus élevée, -0,3027, est observée entre *adiponectin* (µg/mL) et *bmi* (kg/m²).

Cette visualisation permet d'identifier rapidement les couples de variables les plus liés ou les plus indépendants, ce qui est essentiel pour orienter les futures recherches.

Librairies utilisées : plotly.express, pandas et os
Code généré à l'aide de ChatGPT sur la base de requêtes réalisées personnellement.
Fichier python : analysePatients.py

6.2.3 Boxplot par diagnostic

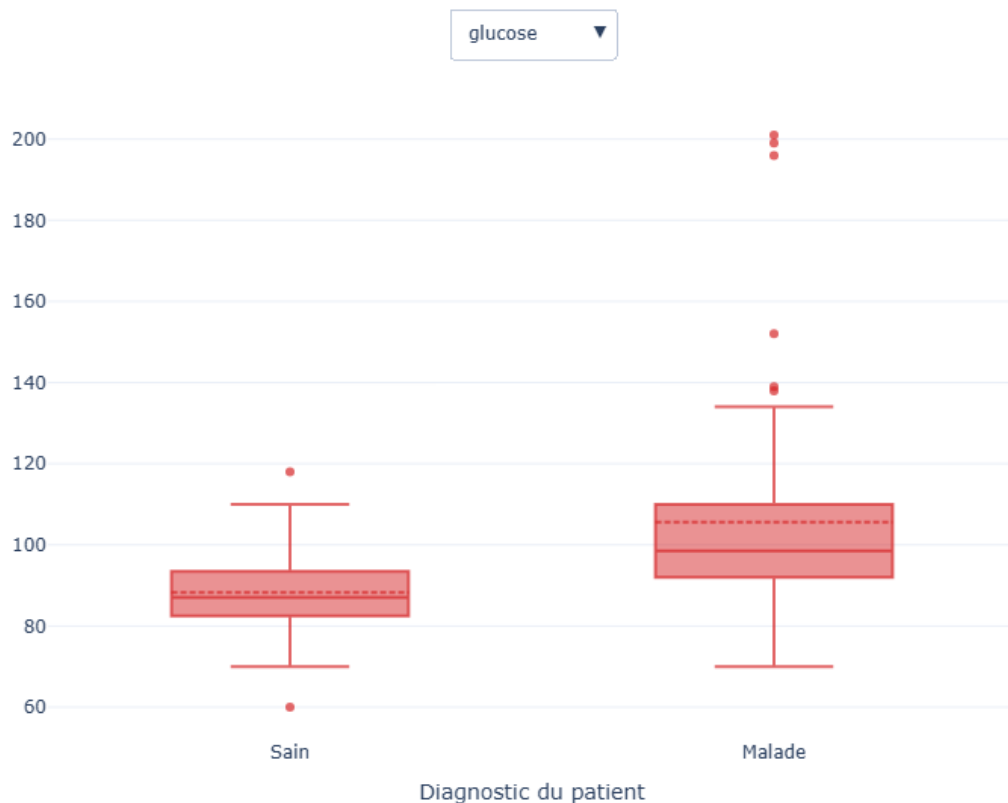


FIGURE 6.13: Boxplot de la variable glucose pour les patients sains et les patients malades

Ce graphique interactif permet à l'utilisateur de sélectionner une variable parmi les données biométriques et sanguines. Deux boxplots sont alors générés : l'un pour les patients sains, l'autre pour les patients malades. Chaque boxplot présente les principales statistiques descriptives, telles que la moyenne, la médiane, les quartiles etc. Par exemple, lorsque la variable *glucose* est sélectionnée, on observe une différence marquée entre les deux groupes. Les patients malades présentent des valeurs de glucose globalement plus élevées et plus dispersées. La moyenne du glucose est de 88,23 mg/dL chez les individus sains, contre 105,56 mg/dL chez les patients malades. Cette représentation permet d'identifier rapidement les variables discriminantes selon le diagnostic, en mettant en évidence les écarts entre les groupes.

Librairies utilisées : plotly.express, pandas et os
Code généré à l'aide de ChatGPT sur la base de requêtes réalisées personnellement.

Fichier python : analysePatients.py

6.2.4 Sunburst interactif

Répartition des Variables Biométriques selon le Diagnostic




FIGURE 6.14: Zoomable Sunburst interactif

Pour visualiser la répartition des valeurs des variables biométriques et sanguines selon le diagnostic, un graphique de type *sunburst* zoomable a été utilisé. Ce graphique hiérarchique est structuré en deux niveaux : le premier cercle représente la classification entre patients sains et patients malades, tandis que les cercles au niveau supérieur détaillent, pour chaque groupe, la moyenne de chaque variable.

Ce type de visualisation permet une navigation intuitive au sein des données et met en évidence les différences ou les similitudes entre les groupes. Par exemple, pour la variable *leptin* (ng/mL), les moyennes sont quasi identiques : 26,5965 ng/mL chez les patients malades contre 26,6379 ng/mL chez les patients sains. Cette faible variation suggère que cette variable, contrairement à d'autres, ne permettrait peut-être pas de distinguer clairement les deux groupes.

Librairies utilisées : plotly.express, pandas et os

Code généré à l'aide de ChatGPT sur la base de requêtes réalisées personnellement.

Fichier python : analysePatients.py

CHAPITRE 7

Prédiction

7.1 Jeu de données sur les biopsies morphologiques d'une tumeur

Ce jeu de données à été basé sur des biopsies mammaires analysées afin d'extraire des caractéristiques précises des cellules tumorales. En entraînant un modèle de prédiction à partir de ces données, il devient possible d'anticiper le caractère dangereux d'une tumeur. Cela représente une aide précieuse pour les professionnels de santé, en facilitant leur prise de décision et en accélérant la détection des cas à risque.

Pour commencer nous avons recherché quel est le meilleur modèle prédictif pour ce jeu de donnés. Nous avons pu suggérer tout à l'heure (voir c.f Visualisation ACP) que les modèles linéaire ne conviendrait pas, nous avons donc décidé d'évaluer les différents modèles sur orange.

Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.915	0.884	0.882	0.886	0.884	0.750
SVM	0.986	0.949	0.949	0.950	0.949	0.891
Neural Network	0.989	0.953	0.952	0.952	0.953	0.898
Random Forest	0.971	0.924	0.924	0.924	0.924	0.838

FIGURE 7.1: Sélection du modèle par Orange

Ici l'erreur la plus grave serait de dire "bénigne" alors qu'elle est maligne, c'est un faux négatif. Donc on cherche à minimiser les faux négatifs. On va donc prioriser le recall et même sans prioriser le recall, le modèle le plus performant ici est le réseau de neurones.

Comment marche le réseau de neurones ? Un réseau de neurones fonctionne comme une série de couches, chacune ayant un rôle spécifique. La première couche reçoit les données brutes (par exemple, les caractéristiques d'une tumeur). Chaque couche suivante prend ces informations et les transforme en détails de plus en plus complexes, comme une sorte de filtrage. Enfin, la dernière couche utilise toutes ces transformations pour donner une réponse finale, comme prédire si la tumeur est bénigne ou maligne. Chaque couche apprend progressivement à extraire des informations importantes, ce qui permet au réseau de faire des prédictions précises.

Code généré par ChatGPT.

On commence par charger un fichier CSV contenant les données d'entraînement. Ces données sont supposées contenir des caractéristiques d'une tumeur (comme le rayon, la texture, etc.) ainsi que la classe de la tumeur (bénigne ou maligne).

On crée un modèle de réseau de neurones avec la bibliothèque Keras. Le modèle est composé de trois couches. Une première couche avec 32 neurones, une deuxième couche avec

16 neurones puis une couche de sortie avec 1 neurone et fonction sigmoid pour la classification. Le modèle est compilé puis entraîné. On finit par crée une application FastAPI qui va servir d'API pour interagir avec le modèle.

```
# Définition du modèle
model = keras.Sequential([
    keras.layers.Dense(32, activation='relu', input_shape=(X_scaled.shape[1],)),
    keras.layers.Dense(16, activation='relu'),
    keras.layers.Dense(1, activation='sigmoid') # Classification binaire
])

# Compilation du modèle
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

# Entraînement du modèle
print("🚀 Entraînement du modèle...")
model.fit(X_scaled, y, epochs=50, batch_size=16, verbose=1)
```

FIGURE 7.2: code entraînement du modèle

Maintenant que notre modèle est prêt on va tester le score sur un deuxième fichier csv.

```
18/18 ————— 0s 5ms/step
✅ Score d'exactitude du modèle : 76.10%
```

FIGURE 7.3: Score du modèle

Le score obtenue n'est pas mauvais mais est insuffisant pour des données médicale. On a réussi à obtenir jusqu'à 82% de précision cependant le nombre de recall avait augmenté à 34. Ce doit être car l'échantillon est trop petit et impossible de trouver des données en plus.

7.2 Jeu de données sur les analyses sanguines

Lors d'une analyse sanguine, il est possible de déterminer si le patient a un risque de cancer. Tous les fichiers sont situés dans un dossier nommé prediction_risque.zip.

Pour choisir notre modèle de prédiction, nous avons testé plusieurs (kNN, SVM, Tree, Random Forest, Logistic Regression) dans le notebook Risque-cancer.ipynb. Au niveau du code, nous avons récupéré un script existant sur kaggle [<https://www.kaggle.com/code/lailymiroj/uas-ai-4>], sélectionné ce que nous avons besoin et adapté le code. Les bibliothèques utilisées sont pandas, sklearn.model_selection, sklearn.metrics pour mettre en forme les données. Voici les résultat obtenus pour chaque modèle :

```
from sklearn.linear_model import LogisticRegression

model_logreg = LogisticRegression(max_iter=10000, solver='lbfgs', multi_class='auto')
model_logreg.fit(X_train, y_train)
y_pred = model_logreg.predict(X_test)

print(classification_report(y_test, y_pred))
```

	precision	recall	f1-score	support
1	0.85	0.92	0.88	12
2	0.91	0.83	0.87	12
accuracy			0.88	24
macro avg	0.88	0.88	0.87	24
weighted avg	0.88	0.88	0.87	24

FIGURE 7.4: Logistic Regression

<pre>from sklearn.tree import DecisionTreeClassifier model_dt = DecisionTreeClassifier() model_dt.fit(X_train,y_train) model_dt = model_dt.predict(X_test) print(classification_report(y_test, y_pred))</pre>					<pre>from sklearn.svm import SVC model_svc = SVC(gamma='scale') model_svc.fit(X_train,y_train) model_svc = model_svc.predict(X_test) print(classification_report(y_test, y_pred))</pre>				
	precision	recall	f1-score	support		precision	recall	f1-score	support
1	0.85	0.92	0.88	12	1	0.85	0.92	0.88	12
2	0.91	0.83	0.87	12	2	0.91	0.83	0.87	12
accuracy			0.88	24	accuracy			0.88	24
macro avg	0.88	0.88	0.87	24	macro avg	0.88	0.88	0.87	24
weighted avg	0.88	0.88	0.87	24	weighted avg	0.88	0.88	0.87	24

FIGURE 7.5: À gauche : Tree ; à droite : SVM

Pour les trois modèles de prédiction, les bibliothèques `sklearn.linear_model`, `sklearn.svm` et `sklearn.Tree` sont utilisées. Les résultats sont exactement les mêmes pour les trois modèles. Les modèles ont une bonne accuracy de 0.88, sont équilibrés entre les deux classes. La classe 2 est un peu moins détectée que la classe 1 au niveau de recall. Les performances sont globalement solides.

<pre>from sklearn.neighbors import KNeighborsClassifier model_knn = KNeighborsClassifier(n_neighbors=3) model_knn.fit(X_train,y_train) y_pred = model_knn.predict(X_test) print(classification_report(y_test, y_pred))</pre>				
	precision	recall	f1-score	support
1	0.50	0.25	0.33	12
2	0.50	0.75	0.60	12
accuracy			0.50	24
macro avg	0.50	0.50	0.47	24
weighted avg	0.50	0.50	0.47	24

FIGURE 7.6: kNN

Pour le modèle de prédiction kNN, la bibliothèque `sklearn.neighbors` est utilisée. Le modèle a une accuracy de 0.50, est déséquilibré entre les deux classes. Il favorise la classe 2 au détriment de la classe 1 en terme de recall. Les performances ne sont pas meilleures qu'un pile ou face.

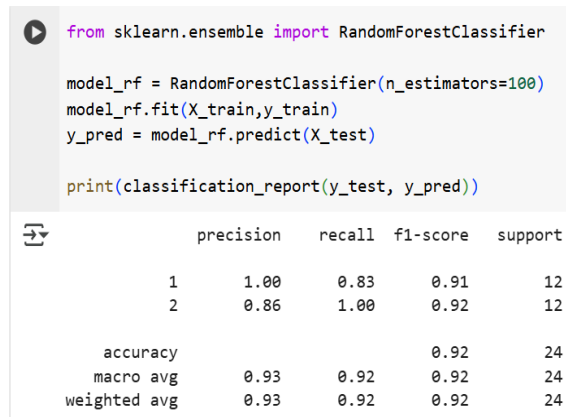


FIGURE 7.7: Random Forest

Pour le modèle de prédiction Random Forest, la librairie `sklearn.ensemble` est utilisée. Le modèle a une bonne accuracy de 0.92, est très équilibré entre les deux classes. La classe 2 est très bien détecté avec un recall de 1.00 et la classe est très précise avec une précision de 1.00. La performance globale est très bonne.

Nous avons décidé de garder le modèle Random Forest.

Sur un site [<https://www.stat4decision.com/fr/foret-aleatoire-avec-python/>], nous avons récupéré le script d'un random forest, donné à ChatGPT pour générer une API et enregistré dans le fichier `essai.py`, voici le code :

```

app = FastAPI()
df = pd.read_csv("dataR2.csv")
X = df.drop(columns=["Classification"])
y = df["Classification"]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=42)
modele_rf = RandomForestClassifier(n_estimators=100, random_state=42)
modele_rf.fit(X_train, y_train)
joblib.dump(modele_rf, "modele_rf.pkl")

class InputData(BaseModel):
    Age: float
    BMI: float
    Glucose: float
    Insulin: float
    HOMA: float
    Leptin: float
    Adiponectin: float
    Resistin: float
    MCP_1: float

@app.post("/predict")
def predict(data: InputData):
    try:
        df_input = pd.DataFrame([data.dict()])
        df_input.rename(columns={"MCP_1": "MCP.1"}, inplace=True) # Harmonisation
        df_input = df_input[X_train.columns] # Vérifier que les colonnes correspondent
        modele_rf = joblib.load("modele_rf.pkl")
        prediction = modele_rf.predict(df_input)
        return {"prediction": int(prediction[0])}
    except Exception as e:
        return {"error": str(e)}

@app.get("/accuracy")
def get_accuracy():
    modele_rf = joblib.load("modele_rf.pkl")
    y_pred = modele_rf.predict(X_test)
    accuracy = accuracy_score(y_test, y_pred)
    return {"accuracy": accuracy}

if __name__ == "__main__":
    import uvicorn
    uvicorn.run(app, host="0.0.0.0", port=8000)

```


FIGURE 7.8: Code `essai.py`

Voici les librairies utilisées : `pandas`, `joblib`, `fastapi`, `pydantic`, `sklearn.ensemble`, `sklearn.model_selection` et `sklearn.metrics`.

Le script `essai.py` charge les données de `dataR2.csv`, entraîne le modèle Random Forest pour prédire la variable `Classification`, génère/sauvegarde le modèle dans le fichier

modele_rf.plk et expose une API FastAPI avec POST/precision (réceptionne les données, les valide et retourne une prédiction 1 ou 2) et GET/recall (retourne l'accuracy sur les données de test). Lors de l'exécution, modele_rf.plk est généré.

La création des pages Web predictionrique.php (style main.css) et traite.php généré par ChatGPT. Pour la page predictionrisque.php, l'utilisateur remplira le formulaire, appuiera sur le bouton prédire et retournera le résultat de la prédiction sur la page traite.php. Mais, nous avons rencontré un problème, l'API fonctionne manuellement mais automatiquement non. Nous avons essayé de résoudre le problème mais en vain.



Formulaire de Prédiction Risque de cancer

Age:

BMI:

Glucose:

Insulin:

HOMA:

Leptin:

Adiponectin:

Resistin:

MCP-1:

FIGURE 7.9: predictionrisque.php

7.3 Prédiction par Deep Learning pour les Images Médicales

7.3.1 Pourquoi le Deep Learning

Le deep learning s'est imposé comme la méthode de choix pour notre système de prédiction grâce à sa capacité exceptionnelle à extraire automatiquement les caractéristiques pertinentes des images médicales. Contrairement aux approches classiques qui nécessitent une extraction manuelle des caractéristiques, les réseaux de neurones profonds apprennent directement à partir des données brutes, captant des motifs visuels complexes et subtils dans les images médicales.

Dans le contexte médical, particulièrement pour la détection de tumeurs, cette capacité est cruciale car les différences entre tissus sains, tumeurs bénignes et malignes peuvent être extrêmement nuancées. Le deep learning offre également une adaptabilité remarquable face à la variabilité des images médicales.

7.3.2 Pourquoi les CNN

Les réseaux de neurones convolutifs (CNN) ont été choisis pour ce projet en raison de leur architecture spécialisée pour le traitement d'images :

- **Détection hiérarchique des caractéristiques** : Les CNN utilisent des couches convolutives qui apprennent progressivement à reconnaître des motifs de plus en plus complexes, des éléments simples (contours, textures) aux structures sophistiquées (formes des tumeurs).
- **Invariance spatiale** : Grâce aux opérations de pooling, les CNN peuvent reconnaître les motifs tumoraux indépendamment de leur position exacte dans l'image.

- **Réduction des paramètres** : Les mécanismes de partage des poids et de pooling réduisent considérablement le nombre de paramètres à entraîner, accélérant l'entraînement et limitant le surapprentissage.
- **Performance éprouvée** : Les CNN ont démontré des performances exceptionnelles dans de nombreuses applications médicales, atteignant parfois des niveaux de précision comparables à ceux des radiologues experts.

7.3.3 Architecture utilisée

Notre modèle a été construit en utilisant le transfer learning avec le réseau VGG16 comme base :

```

1 base_model = VGG16(input_shape=(224, 224, 3), include_top=False,
2   weights='imagenet')
3
4 base_model.trainable = False # Figer la base pour accélérer l'
5   entraînement
6
7 model = Sequential([
8   base_model,
9   Flatten(),
10  Dense(256, activation='relu'),
11  Dropout(0.5),
12  Dense(len(train_data.class_indices), activation='softmax')
13 ])
14 model.compile(
15   optimizer=tf.keras.optimizers.Adam(learning_rate=0.0001),
16   loss='categorical_crossentropy',
17   metrics=['accuracy'])

```

Listing 7.1: Implémentation du transfer learning avec VGG16

7.3.4 Source de données

Les données utilisées proviennent d'un ensemble d'images médicales issues de scanners et d'IRM, organisées dans un dataset structuré nommé "dataset_Resized". Ce jeu de données contient des images médicales réparties en trois catégories : bénignes, malignes et normales. Toutes les images ont été redimensionnées à 224×224 pixels pour assurer la compatibilité avec notre architecture CNN.

7.3.5 Traitement des images

Nous avons appliqué plusieurs techniques de traitement d'images :

```

1 train_datagen = ImageDataGenerator(
2   rescale=1./255,
3   rotation_range=15,
4   horizontal_flip=True,
5   zoom_range=0.1
6 )
7 validation_datagen = ImageDataGenerator(rescale=1./255)
8 test_datagen = ImageDataGenerator(rescale=1./255)

```

Listing 7.2: Prétraitement et augmentation des données

Ces techniques incluent :

- **Normalisation** : Les valeurs des pixels sont normalisées dans la plage $[0,1]$.
- **Augmentation de données** : Rotations aléatoires ($\pm 15^\circ$), retournements horizontaux et zoom aléatoire ($\pm 10\%$).

7.3.6 Division de la base de données

Nous avons divisé notre jeu de données de manière stratifiée :

- Ensemble d'entraînement (75%)
- Ensemble de validation (15%)
- Ensemble de test (10%)

```

1 # R partition automatique des images
2 for cls in classes:
3     cls_path = os.path.join(source_folder, cls)
4     images = os.listdir(cls_path)
5     random.shuffle(images)
6
7     total_images = len(images)
8     train_count = int(total_images * train_ratio)
9     val_count = int(total_images * validation_ratio)
10
11     train_images = images[:train_count]
12     validation_images = images[train_count:train_count +
13                                val_count]
13     test_images = images[train_count + val_count:]

```

Listing 7.3: Division stratifiée des données

7.3.7 Résultats avant amélioration

Notre modèle CNN initial présentait les limitations suivantes :

- **Précision globale** : 72% sur l'ensemble de test
- **Matrice de confusion** : Tendance à confondre certains cas de tumeurs malignes avec des tumeurs bénignes
- **Courbe d'apprentissage** : Signes de surapprentissage après quelques époques
- **Temps d'entraînement** : Relativement long en raison de l'apprentissage from scratch

7.3.8 Amélioration avec VGG et autres techniques

Pour surmonter ces limitations, nous avons implémenté :

- **Transfer Learning avec VGG16** : Utilisation des poids pré-entraînés sur ImageNet pour extraire des caractéristiques générales.
- **Techniques de régularisation avancées** :

```

1 early_stop = EarlyStopping(monitor='val_loss', patience=5,
2                             restore_best_weights=True)
3 reduce_lr = ReduceLROnPlateau(monitor='val_loss', factor
4                                =0.5, patience=2, verbose=1)

```

Listing 7.4: Techniques de régularisation

7.3.9 Résultats après amélioration

Nos améliorations ont porté leurs fruits :

- **Précision globale** : 86.56% sur l'ensemble de test (+14.56%)

- **Performances par classe :**
 - Bénin : 87% de précision, 92% de rappel, 89% de F1-score
 - Malin : 84% de précision, 81% de rappel, 82% de F1-score
 - Normal : 89% de précision, 79% de rappel, 84% de F1-score

Matrice de confusion:

```
[[194  14   4]
 [ 20  87   1]
 [   9   2  41]]
```

Ces résultats sont visualisés à travers plusieurs graphiques générés automatiquement à partir des données calculées dans `train_model.py` :

```
1 # Cr ation du JSON Final de R sultats
2 results = {
3     "test_accuracy": float(test_accuracy),
4     "confusion_matrix": cm.tolist(),
5     "classification_report": report,
6     "roc_data": roc_data,
7     "clustering_data": clustering_data,
8     "training_history": training_history
9 }
```

Listing 7.5: Génération des données pour visualisations




FIGURE 7.10: Matrice de confusion du modèle




FIGURE 7.11: Courbes ROC pour chaque classe




FIGURE 7.12: Clustering 3D des caractéristiques

7.3.10 Expérience sur Orange et développement Flask

Cette approche a d'abord été testée sur la plateforme Orange, où nous avons obtenu des résultats prometteurs avec un réseau de neurones atteignant une AUC de 0.970 et une précision de 0.896, surpassant d'autres classificateurs comme SVM et Random Forest.

Lors de l'implémentation dans un environnement de production, nous avons rencontré quelques défis avec Flask pour le déploiement du modèle, notamment des problèmes de mémoire lors du traitement d'images haute résolution. Pour résoudre ce problème, nous avons développé une approche de division d'images qui segmente les grandes images en sections plus petites avant la prédiction.

7.3.11 Conclusions

Notre travail démontre l'efficacité du deep learning, particulièrement des CNN avec transfer learning, pour la classification d'images médicales :

1. **Efficacité du transfer learning** : L'utilisation de VGG16 a considérablement amélioré les performances.
2. **Importance de l'augmentation de données** : Ces techniques ont joué un rôle crucial dans la robustesse du modèle.
3. **Équilibre précision-rappel** : Le modèle a été optimisé pour minimiser les faux négatifs tout en maintenant une précision élevée.
4. **Interprétabilité visuelle** : Les visualisations offrent une transparence essentielle pour l'adoption clinique.
5. **Validation par métriques** : L'analyse de l'AUC, la F1-score et le clustering confirment la robustesse du modèle.

À l'avenir, nous envisageons d'explorer d'autres architectures comme ResNet ou EfficientNet, ainsi que d'intégrer des techniques de segmentation pour localiser précisément les tumeurs au sein des images.

CHAPITRE 8

Conclusion

La transformation d'Oncoanalyse a permis de convertir une interface rudimentaire en une plateforme médicale complète et intuitive. En intégrant cinq fonctionnalités complémentaires – présentation, exploration interactive, visualisation personnalisée, prédiction par images et analyse statistique – nous avons créé un outil cohérent facilitant l'analyse des tumeurs mammaires.

Les défis techniques rencontrés ont renforcé nos compétences en intégration de technologies (PHP, MySQL, JavaScript) et en collaboration via Git. Malgré quelques aspects nécessitant encore des améliorations, comme l'automatisation complète de l'API de prédiction, la base solide établie permettra des évolutions futures simplifiées.

Oncoanalyse illustre parfaitement comment une interface bien conçue peut transformer des données médicales complexes en informations actionnables, contribuant potentiellement à améliorer le diagnostic et le suivi des tumeurs mammaires.

Bibliographie

- http://mediatheque.lecrips.net/doc_num.php?explnum_id=48927
- Cours d'Analyse Exploratoire des Données 1
- Cours d'Analyse Exploratoire des Données 2
- Cours de Modélisation et Méthodes Statistiques
- Cours de Sciences des Données 3
- Cours de Base de Données 2
- <https://www.stat4decision.com/fr/foret-aleatoire-avec-python/>
- kaggle
- ChatGPT
- <https://www.youtube.com/watch?v=gPVVsw20WdM&t=349s>
- <https://www.youtube.com/watch?v=iWS9ogMP0I0>